

Projet de Machine Learning appliqué à la Business Intelligence

Estimation de la valeur client et segmentation comportementale — 2026

Contexte

Ce projet a porté sur l'analyse data complète d'un **grossiste B2B suisse spécialisé dans les articles pour la maison, les soins et le bricolage**. Les clients de ce grossiste étant des magasins revendeurs (et non des particuliers), la modélisation a été orientée vers l'analyse du comportement d'achat plutôt que vers les attributs personnels du gérant.

Objectifs : estimer la Valeur Vie Client (CLV / VVC), segmenter la base clients pour personnaliser l'action commerciale, et identifier les meilleures opportunités de croissance à partir de l'historique des ventes.

Volumétrie traitée : 631 905 transactions, 5 340 magasins clients, 3 983 produits, 2 114 communes.

Outils : Dataiku DSS pour l'ensemble du pipeline (ingestion, préparation, modélisation, dashboard).

Démarche — Pipeline data de bout en bout

Le projet s'est structuré en quatre temps :

1. **Préparation** — Ingestion de cinq sources hétérogènes, nettoyage, conversion de types, jointures multi-clés et gestion des valeurs aberrantes (écrêtage de la CLV au 99^e percentile pour neutraliser les outliers extrêmes).
2. **Feature engineering** — Construction de sept variables comportementales dérivées des transactions (fréquence d'achat, panier moyen, produits par commande, quantité moyenne, mois d'activité reconstruits manuellement, CA mensualisé, CLV sur 36 mois). Protection systématique des ratios contre la division par zéro.
3. **Modélisation** — Apprentissage supervisé (régression sur la CLV) et non supervisé (segmentation client).
4. **Activation** — Score d'implantation pour le choix de magasins, sélection des 100 meilleurs clients, recommandation produit par segment et génération automatique d'un mailing personnalisé.

Modèle supervisé — Prédiction de la Valeur Vie Client

Question méthodologique

La valeur d'un client est-elle mieux expliquée par *qui il est* (profil démographique et régional) ou par *comment il achète* (comportement) ? Pour trancher, deux modèles concurrents ont été entraînés et comparés.

Résultats

Approche	Variables	R ²
Modèle « profil »	canton, langue, démographie de la commune	≈ 0,02
Modèle « comportement » (Ridge)	ratios d'achat + contexte régional	0,80
Modèle « comportement » (Random Forest)	idem	0,957

Choix du modèle final et justification

Le **Random Forest** a été retenu pour sa robustesse aux relations non linéaires, sa gestion native des interactions entre variables et son absence de besoin de normalisation. L'analyse de l'importance des variables a confirmé que la **fréquence d'achat** et le **panier moyen** dominent largement, suivis par des facteurs de contexte (population, canton, fréquentation, marché linguistique).

Gestion du data leakage

Une attention particulière a été portée à l'exclusion des variables corrélées par construction à la cible (chiffre d'affaires, marge, VVC elle-même), pour garantir que la performance du modèle n'était pas artificiellement gonflée par une fuite de la cible dans les features.

Modèle non supervisé — Segmentation comportementale

Méthode

Un algorithme **K-Means** a été appliqué aux variables comportementales standardisées, après normalisation pour éviter qu'une variable à forte amplitude domine la distance euclidienne.

Choix du nombre de clusters — justification

Le nombre de groupes a été déterminé par comparaison du score de silhouette pour plusieurs valeurs :

k	Silhouette	Décision
3	0,261	Trop grossier
5	0,335	Retenu — meilleur score
7	0,295	Sur-segmentation

Un **test d'ablation** a également été mené en retirant successivement chaque variable pour vérifier sa contribution réelle : le retrait de la variable « mois d'activité » faisait chuter la silhouette à 0,26, ce qui a justifié de la conserver dans le modèle final.

Résultat — 5 segments actionnables

Segment	Part	Caractéristiques
Nouveaux clients actifs	37 %	Récents, fréquents, petits paniers
Anciens dormants	35 %	Fidèles mais peu actifs (cible de réactivation)
Acheteurs variés	12 %	Gros paniers, large gamme
Gros volumes fréquents	7 %	Commandes importantes régulières
Premium fidèles	7 %	Cœur de valeur

Activation business des modèles

- **Sélection des 100 meilleurs clients** par CLV décroissante. La cohérence des modèles a été validée par le constat que ces clients appartiennent majoritairement aux segments « Premium fidèles » et « Gros volumes ».
- **Système de recommandation produit** : à chaque client est associé le best-seller de son segment ainsi qu'une alternative de rang 2 (logique de cross-sell).
- **Mailing automatisé trilingue** : 200 messages personnalisés générés en français, allemand ou italien selon l'attribut linguistique du client, via une formule conditionnelle. Le pipeline est entièrement reproductible.

Limites et améliorations identifiées

Le R^2 élevé du modèle de CLV (0,96) s'explique en partie par le fait que la fréquence et le panier moyen sont, par construction, fortement liés à la cible. Cette honnêteté méthodologique a été mise en avant dans la restitution. **Piste d'amélioration** : pour prédire la valeur des *nouveaux* clients, recalculer les ratios comportementaux sur une fenêtre initiale (les trois premiers mois d'activité), afin de produire des prédictions prospectives à partir des seuls premiers signaux d'achat.

Compétences mises en œuvre

- **Machine Learning** : régression (Ridge, Random Forest), clustering (K-Means), évaluation par R^2 et silhouette, détection de data leakage, justification des hyperparamètres.
- **Feature engineering** : construction de variables dérivées, gestion des dates, normalisation, traitement des valeurs aberrantes.
- **Pipeline data** : maîtrise de Dataiku DSS (Prepare, Join, Group, Top N, Window), construction d'un flux reproductible.
- **Analyse statistique** : analyses univariées et bivariées, corrélations de Spearman, lecture critique des résultats.
- **Communication** : dashboard, rapport structuré, vulgarisation des résultats techniques en recommandations business.

Pour toute information complémentaire, je reste à votre disposition.